01 — Importação e Limpeza dos Dados

Bibliometria de Gêmeos Digitais para Cidades Inteligentes

Leonardo Camilo

2026-03-13

Table of contents

1 Introdução **1**

2 Carregar Pacotes **1**

3 String de Busca **2**

4 Importar Dados **2**

5 Exploração Inicial **3**

6 Limpeza dos Dados **4**

6.1 Remover Duplicatas 4

6.2 Verificar Valores Ausentes 5

6.3 Verificar Período 6

7 Análise Bibliométrica Geral **6**

8 Exportar Dados Processados **12**

9 Resumo **13**

1 Introdução

Este notebook importa os dados bibliográficos exportados do Scopus e realiza a limpeza inicial do dataset. O resultado é um dataframe padronizado pronto para as análises bibliométricas dos notebooks seguintes.

2 Carregar Pacotes

```
library(bibliometrix)
library(tidyverse)
library(here)
```

3 String de Busca

A string de busca utilizada neste estudo:

`TITLE-ABS-KEY("digital twin*" AND ("smart cit*" OR "urban*"))`

Filtros aplicados:

- Período: 2015–2024
- Tipo de documento: Article
- Idioma: English

O operador `*` (truncamento) garante que variações como "digital twin" e "digital twins" sejam capturadas, assim como "smart city" e "smart cities", "urban" e "urbanization", etc.

4 Importar Dados

O `bibliometrix` possui a função `convert2df()` que converte arquivos bibliográficos de diversas fontes em um dataframe padronizado.

```r
# Caminho para o arquivo exportado do Scopus
# NOTA: Ajuste o nome do arquivo conforme o que foi salvo na pasta data/raw/
arquivo_bib <- here("data", "raw", "scopus.bib")

# Verificar se o arquivo existe
if (!file.exists(arquivo_bib)) {
  stop(
    "Arquivo não encontrado: ", arquivo_bib, "\n",
    "Por favor, exporte os dados do Scopus e salve em data/raw/scopus.bib\n",
    "Consulte as instruções no início deste notebook."
  )
}

# Converter o arquivo BibTeX para um dataframe do bibliometrix
# dbsource = "scopus" indica a base de origem
# format = "bibtex" indica o formato do arquivo
df <- convert2df(file = arquivo_bib, dbsource = "scopus", format = "bibtex")
```

```
Converting your scopus collection into a bibliographic dataframe


Warning:
In your file, some mandatory metadata are missing. Bibliometrix functions may not work properly

Please, take a look at the vignettes:
- 'Data Importing and Converting' (https://www.bibliometrix.org/vignettes/Data-Importing-and-Co
- 'A brief introduction to bibliometrix' (https://www.bibliometrix.org/vignettes/Introduction_t
```

```
Missing fields:  CR
Done!


Generating affiliation field tag AU_UN from C1:  Done!
```

```r
# Dimensões do dataset: quantos artigos e quantas variáveis
cat("Número de artigos:", nrow(df), "\n")
```

```
Número de artigos: 671
```

```r
cat("Número de variáveis:", ncol(df), "\n")
```

```
Número de variáveis: 36
```

5 Exploração Inicial

Explorando a estrutura do dataset para entender os campos disponíveis.

```r
# Visualizar os primeiros registros
glimpse(df)
```

```
Rows: 671
Columns: 36
$ AU                <chr> "PLACHINDA P;MORGAN J;COELHO M", "LIU D;SUN C;CHEN J~
$ KW_Merged         <chr> "DATA FORECASTING; DATA INTEGRATION; DATA VISUALIZAT~
$ DE                <chr> "DATA FORECASTING; DATA INTEGRATION; DATA VISUALIZAT~
$ ID                <chr> "IDAHO; IDAHO NATIONAL LABORATORY; UNITED STATES; CA~
$ C1                <chr> "IDAHO NATIONAL LABORATORY, IDAHO FALLS, 83415, ID, ~
$ JI                <chr> "SUSTAINABILITY", "J. COMPUT. CIV. ENG.", "PROC. NAT~
$ AB                <chr> "AS THE CONCENTRATION OF GREENHOUSE GASES (GHGS) IN ~
$ coden             <chr> NA, "JCCEE", "PNASA", NA, "ASEDD", NA, "EMSOF", "ICO~
$ RP                <chr> "J. MORGAN; IDAHO NATIONAL LABORATORY, IDAHO FALLS, ~
$ DI                <chr> "10.3390/su15010163", "10.1061/JCCEE5.CPENG-5354", "~
$ SN                <chr> "20711050", "08873801", "00278424", "22131388", "136~
$ SO                <chr> "SUSTAINABILITY (SWITZERLAND)", "JOURNAL OF COMPUTIN~
$ LA                <chr> "ENGLISH", "ENGLISH", "ENGLISH", "ENGLISH", "ENGLISH~
$ TC                <dbl> 9, 15, 18, 19, 5, 3, 14, 41, 43, 27, 22, 8, 12, 2, 3~
$ PN                <chr> "1", "5", "42", NA, "16", "2", NA, "8", "11", NA, NA~
$ PP                <chr> "", "", "", "", "2879 - 2900", "150 - 172", "", "140~
$ pmid              <chr> NA, NA, "36215503", NA, NA, NA, NA, NA, NA, NA, NA, ~
$ publication_stage <chr> "FINAL", "FINAL", "FINAL", "FINAL", "FINAL", "FINAL"~
$ PU                <chr> "MDPI", "AMERICAN SOCIETY OF CIVIL ENGINEERS (ASCE)"~
$ DB                <chr> "SCOPUS", "SCOPUS", "SCOPUS", "SCOPUS", "SCOPUS", "S~
$ TI                <chr> "TOWARDS NET ZERO: MODELING APPROACH TO THE RIGHT-SI~
$ DT                <chr> "ARTICLE", "ARTICLE", "ARTICLE", "ARTICLE", "ARTICLE~
$ url               <chr> "https://www.scopus.com/inward/record.uri?eid=2-s2.0~
$ VL                <chr> "15", "37", "119", "64", "27", "10", "171", "61", "2~
$ PY                <dbl> 2023, 2023, 2022, 2024, 2024, 2023, 2024, 2023, 2022~
$ AF                <chr> "PLACHINDA PAUL;MORGAN JULIA;COELHO MARIA", "LIU DON~
```

```
$ J9                <chr> "SUSTAINABILITY", "J COMPUT CIV ENG", "PROC NATL ACA~
$ AB_raw            <chr> "As the concentration of greenhouse gases (GHGs) in ~
$ TI_raw            <chr> "Towards Net Zero: Modeling Approach to the Right-Si~
$ DE_raw            <chr> "data forecasting; data integration; data visualizat~
$ CR                <chr> "none", "none", "none", "none", "none", "none", "non~
$ AU_UN             <chr> "IDAHO NATIONAL LABORATORY", "TIANJIN UNIV.;UNIV. OF~
$ AU1_UN            <chr> "NOTREPORTED;IDAHO NATIONAL LABORATORY;NOTREPORTED",~
$ AU_UN_NR          <lgl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~
$ SR_FULL           <chr> "PLACHINDA P, 2023, SUSTAINABILITY", "LIU D, 2023, J~
$ SR                <chr> "PLACHINDA P, 2023, SUSTAINABILITY", "LIU D, 2023, J~
```

```r
# Campos mais relevantes para a análise bibliométrica:
# AU = Autores
# TI = Título
# SO = Periódico (Source)
# DT = Tipo de documento
# DE = Keywords do autor
# ID = Keywords Plus (indexadas)
# AB = Abstract
# TC = Total de citações
# PY = Ano de publicação
# AU_CO = País do primeiro autor

# Verificar campos disponíveis
cat("Campos disponíveis no dataset:\n")
```

```
Campos disponíveis no dataset:
```

```r
cat(paste(names(df), collapse = ", "), "\n")
```

```
AU, KW_Merged, DE, ID, C1, JI, AB, coden, RP, DI, SN, SO, LA, TC, PN, PP, pmid, publication_sta
```

6 Limpeza dos Dados

6.1 Remover Duplicatas

```r
# Verificar duplicatas baseado no DOI (Digital Object Identifier)
n_antes <- nrow(df)

# Identificar duplicatas pelo título (mais robusto que DOI, que pode estar ausente)
df <- df %>%
  distinct(TI, .keep_all = TRUE)

n_depois <- nrow(df)
n_removidos <- n_antes - n_depois

cat("Artigos antes da remoção de duplicatas:", n_antes, "\n")
```

```
Artigos antes da remoção de duplicatas: 671
```

```r
cat("Artigos após remoção de duplicatas:", n_depois, "\n")
```

```
Artigos após remoção de duplicatas: 671
```

```r
cat("Duplicatas removidas:", n_removidos, "\n")
```

```
Duplicatas removidas: 0
```

6.2 Verificar Valores Ausentes

```r
# Verificar proporção de NAs nos campos mais importantes
campos_chave <- c("AU", "TI", "SO", "PY", "TC", "DE", "ID", "AB")

# Calcular NAs para cada campo
na_info <- sapply(campos_chave, function(campo) {
  if (campo %in% names(df)) {
    sum(is.na(df[[campo]]) | df[[campo]] == "")
  } else {
    NA
  }
})

# Exibir resultado
na_tabela <- data.frame(
  Campo = campos_chave,
  Descricao = c("Autores", "Título", "Periódico", "Ano",
                "Citações", "Keywords Autor", "Keywords Plus", "Abstract"),
  NAs = na_info,
  Percentual = round(na_info / nrow(df) * 100, 1)
)

knitr::kable(na_tabela, caption = "Valores ausentes nos campos principais")
```

Table 1: Valores ausentes nos campos principais

	Campo	Descricao	NAs	Percentual
AU	AU	Autores	0	0.0
TI	TI	Título	0	0.0
SO	SO	Periódico	0	0.0
PY	PY	Ano	0	0.0
TC	TC	Citações	0	0.0
DE	DE	Keywords Autor	44	6.6
ID	ID	Keywords Plus	192	28.6
AB	AB	Abstract	1	0.1

6.3 Verificar Período

```r
# Confirmar que todos os artigos estão no período desejado (2015-2024)
cat("Período dos dados:\n")
```

```
Período dos dados:
```

```r
cat("  Ano mínimo:", min(df$PY, na.rm = TRUE), "\n")
```

```
  Ano mínimo: 2018
```

```r
cat("  Ano máximo:", max(df$PY, na.rm = TRUE), "\n")
```

```
  Ano máximo: 2024
```

```r
# Tabela de frequência por ano
table(df$PY) %>%
  as.data.frame() %>%
  setNames(c("Ano", "Artigos")) %>%
  knitr::kable(caption = "Distribuição de artigos por ano")
```

Table 2: Distribuição de artigos por ano

Ano	Artigos
2018	2
2019	3
2020	37
2021	58
2022	126
2023	159
2024	286

7 Análise Bibliométrica Geral

O `bibliometrix` oferece a função `biblioAnalysis()` que gera um resumo completo das principais estatísticas do corpus.

Glossário das métricas do `summary(biblioAnalysis())`:

- **TC** — *Total Citations*: número total de citações recebidas pelo artigo
- **NTC** — *Normalized Total Citations*: citações normalizadas pelo ano de publicação (permite comparar artigos de anos diferentes)
- **TCperYear** — *Total Citations per Year*: média de citações por ano desde a publicação
- **SCP** — *Single Country Publications*: artigos em que todos os autores são do mesmo país (sem colaboração internacional)
- **MCP** — *Multiple Country Publications*: artigos com autores de dois ou mais países (colaboração internacional)
- **MCP_Ratio** — Proporção de MCP sobre o total de publicações do país. Valores próximos de 1 indicam que quase toda a produção do país é feita em colaboração internacional; valores próximos de 0 indicam produção predominantemente doméstica

```r
# Gerar análise bibliométrica geral
resultados <- biblioAnalysis(df)

# Exibir resumo das principais métricas
summary(resultados, k = 10)
```

```
MAIN INFORMATION ABOUT DATA

 Timespan                             2018 : 2024
 Sources (Journals, Books, etc)       312
 Documents                            671
 Annual Growth Rate %                 128.7
 Document Average Age                 3.13
 Average citations per doc            41.94
 Average citations per year per doc   8.68
 References                           1

DOCUMENT TYPES
 article      671

DOCUMENT CONTENTS
 Keywords Plus (ID)                   4119
 Author's Keywords (DE)               2247

AUTHORS
 Authors                              2261
 Author Appearances                   2849
 Authors of single-authored docs      47

AUTHORS COLLABORATION
 Single-authored docs                 48
 Documents per Author                 0.297
 Co-Authors per Doc                   4.25
 International co-authorships %       30.55


Annual Scientific Production

 Year    Articles
    2018        2
    2019        3
    2020       37
    2021       58
    2022      126
    2023      159
```

2024 286

Annual Percentage Growth Rate 128.68

Most Productive Authors

	Authors	Articles	Authors	Articles Fractionalized
1	LV Z	15	WANG Y	4.27
2	WANG Y	15	LV Z	3.65
3	LI X	14	LI Y	2.86
4	LI Y	12	LI X	2.37
5	LI J	10	ZHANG Y	2.32
6	PARK S	10	ZHANG K	2.01
7	ZHANG X	9	PARK S	2.01
8	ZHANG Y	9	KURU K	2.00
9	BILJECKI F	6	CHEN D	1.92
10	CHEN D	6	BILJECKI F	1.89

Top manuscripts per citations

	Paper	
1	FULLER A, 2020, IEEE ACCESS	10.1109/ACCESS.2
2	MINERVA R, 2020, PROC IEEE	10.1109/JPROC.20
3	ALLAM Z, 2022, SMART CITIES	10.3390/smartcit
4	DENG T, 2021, J MANAG SCI ENG	10.1016/j.jmse.2
5	DEMBSKI F, 2020, SUSTAINABILITY	10.3390/su120623
6	WHITE G, 2021, CITIES	10.1016/j.cities
7	SCHROTTER G, 2020, PFG - J PHOTOGRAMMETRY REMOTE SENSING GEOINFORMATION SCI	10.1007/s41064-0
8	DENG M, 2021, J INF TECHNOL CONSTR	10.36680/J.ITCON
9	LI X, 2022, FUTURE GENER COMPUT SYST	10.1016/j.future
10	FRANCISCO A, 2020, J MANAGE ENG	10.1061/(ASCE)MI

	TCperYear	NTC
1	291.6	10.86
2	93.0	3.47
3	109.4	9.00
4	85.8	6.84
5	72.7	2.71
6	76.7	6.11
7	63.4	2.36
8	62.8	5.01
9	66.8	5.49
10	43.7	1.63

Corresponding Author's Countries

	Country	Articles	Freq	SCP	MCP	MCP_Ratio
1	CHINA	132	0.2204	85	47	0.356
2	UNITED KINGDOM	49	0.0818	34	15	0.306
3	USA	47	0.0785	40	7	0.149
4	KOREA	43	0.0718	38	5	0.116
5	ITALY	42	0.0701	35	7	0.167
6	SPAIN	24	0.0401	19	5	0.208
7	GERMANY	19	0.0317	14	5	0.263
8	HONG KONG	16	0.0267	9	7	0.438
9	NETHERLANDS	16	0.0267	6	10	0.625
10	SWEDEN	15	0.0250	4	11	0.733

SCP: Single Country Publications

MCP: Multiple Country Publications

Total Citations per Country

	Country	Total Citations	Average Article Citations
1	CHINA	5027	38.08
2	UNITED KINGDOM	3935	80.31
3	USA	1977	42.06
4	FRANCE	1735	173.50
5	KOREA	1224	28.47
6	ITALY	990	23.57
7	NETHERLANDS	921	57.56
8	SPAIN	895	37.29
9	SWITZERLAND	866	123.71
10	SINGAPORE	700	63.64

Most Relevant Sources

	Sources	Articles
1	SUSTAINABILITY (SWITZERLAND)	30
2	SUSTAINABLE CITIES AND SOCIETY	22
3	IEEE ACCESS	19
4	SUSTAINABLE ENERGY TECHNOLOGIES AND ASSESSMENTS	18
5	APPLIED SCIENCES (SWITZERLAND)	17
6	REMOTE SENSING	16
7	BUILDINGS	14
8	IEEE INTERNET OF THINGS JOURNAL	11
9	INTERNATIONAL JOURNAL OF APPLIED EARTH OBSERVATION AND GEOINFORMATION	10
10	ISPRS INTERNATIONAL JOURNAL OF GEO-INFORMATION	10

```
Most Relevant Keywords

   Author Keywords (DE)      Articles  Keywords-Plus (ID)     Articles
1    DIGITAL TWIN                 233 SMART CITY                  169
2    DIGITAL TWINS                109 DECISION MAKING              76
3    SMART CITY                    72 URBAN PLANNING               65
4    SMART CITIES                  57 INTERNET OF THINGS           64
5    ARTIFICIAL INTELLIGENCE       31 DIGITAL TWIN                 59
6    DEEP LEARNING                 27 DEEP LEARNING                53
7    INTERNET OF THINGS            26 URBAN AREA                   50
8    URBAN PLANNING                23 SUSTAINABLE DEVELOPMENT      38
9    MACHINE LEARNING              22 ARTIFICIAL INTELLIGENCE      35
10   VIRTUAL REALITY               18 INFORMATION MANAGEMENT       35
```

```r
# Gráficos automáticos do bibliometrix
# Estes gráficos dão uma visão geral rápida do corpus
plot(resultados, k = 10)
```

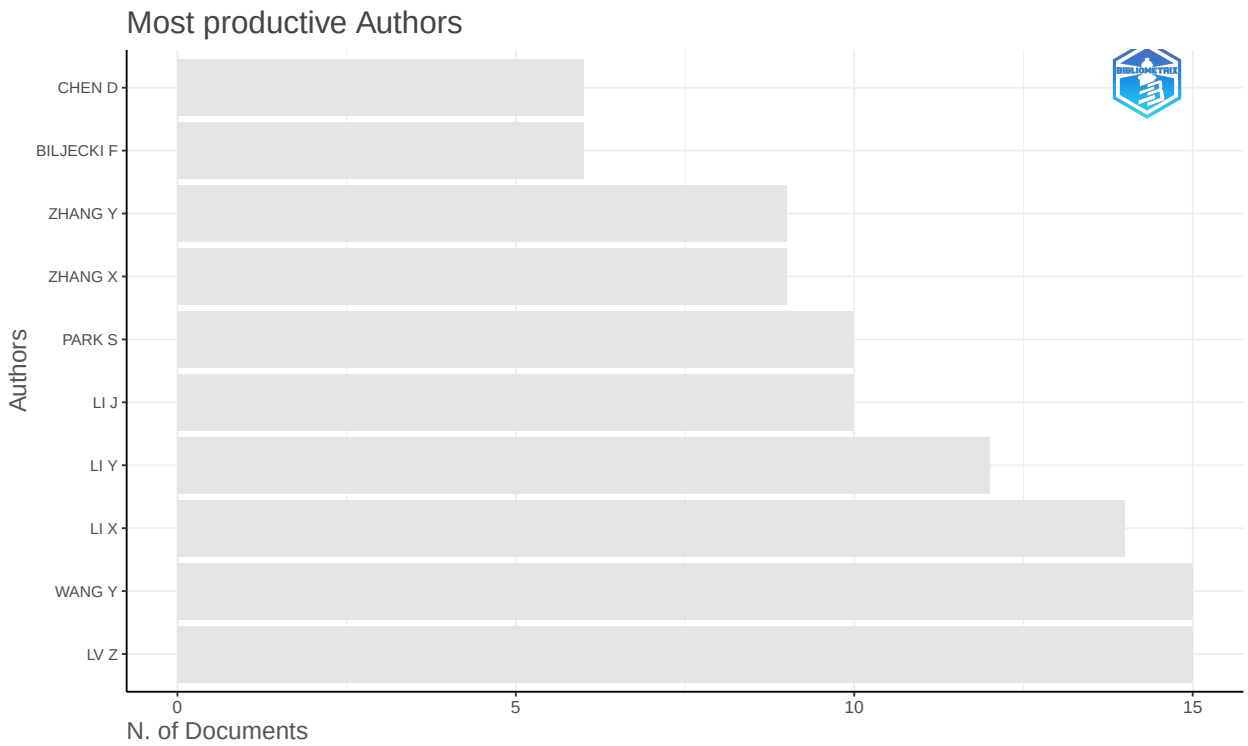

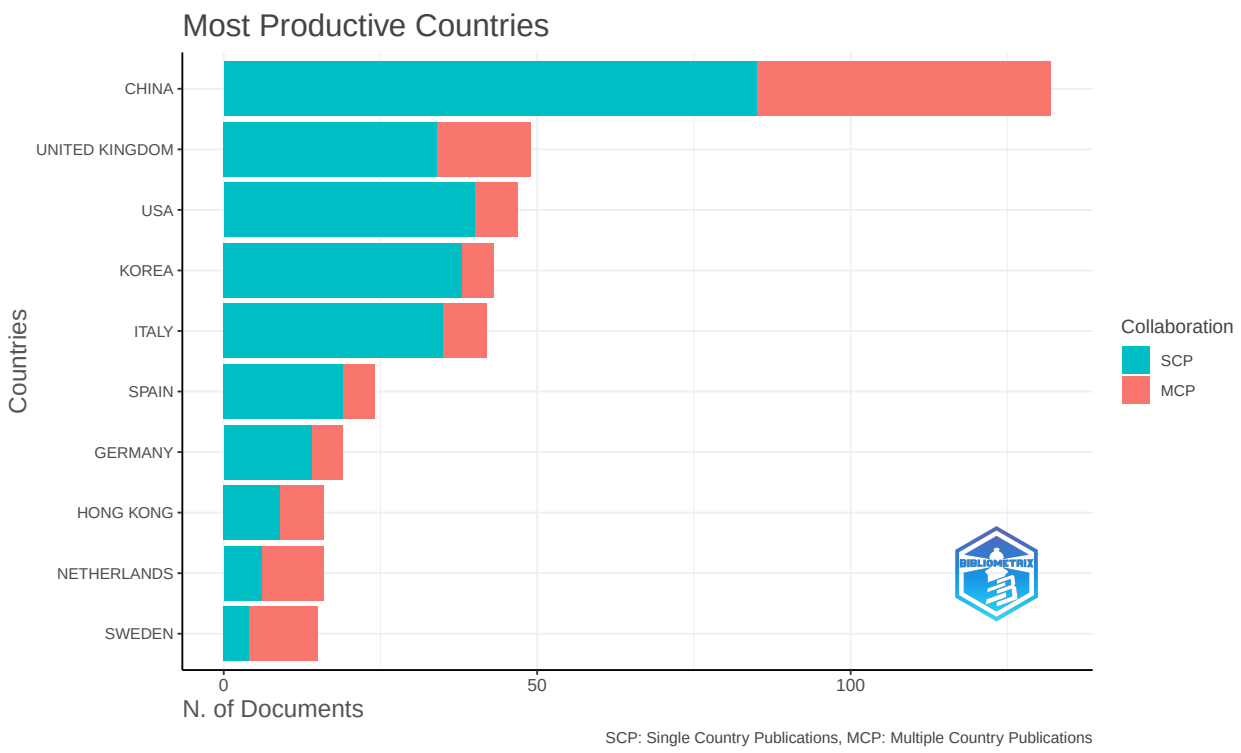
Most Productive Countries
CHINA
UNITED KINGDOM
USA
KOREA
ITALY
SPAIN
GERMANY
HONG KONG
NETHERLANDS
SWEDEN
Countries
0
50
100
N. of Documents
Collaboration
SCP
MCP
SCP: Single Country Publications, MCP: Multiple Country Publications

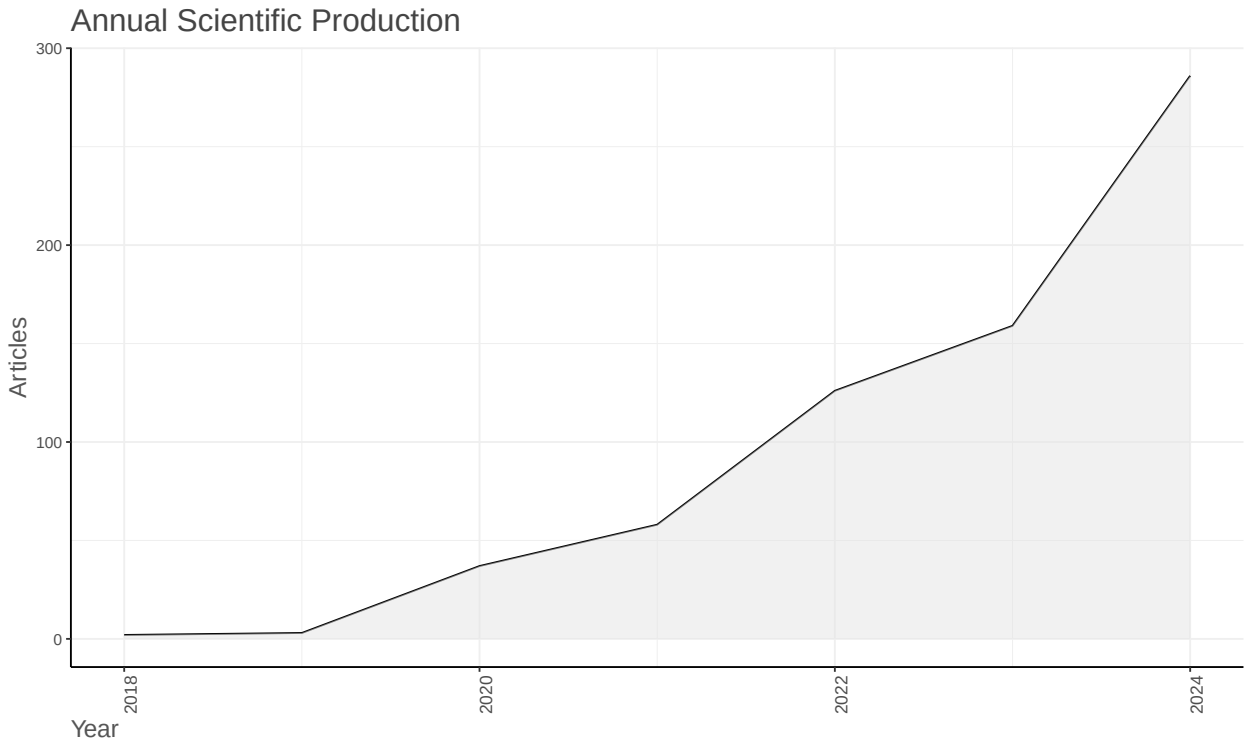
Annual Scientific Production
300
200
100
0
Articles
2018
2020
2022
2024
Year

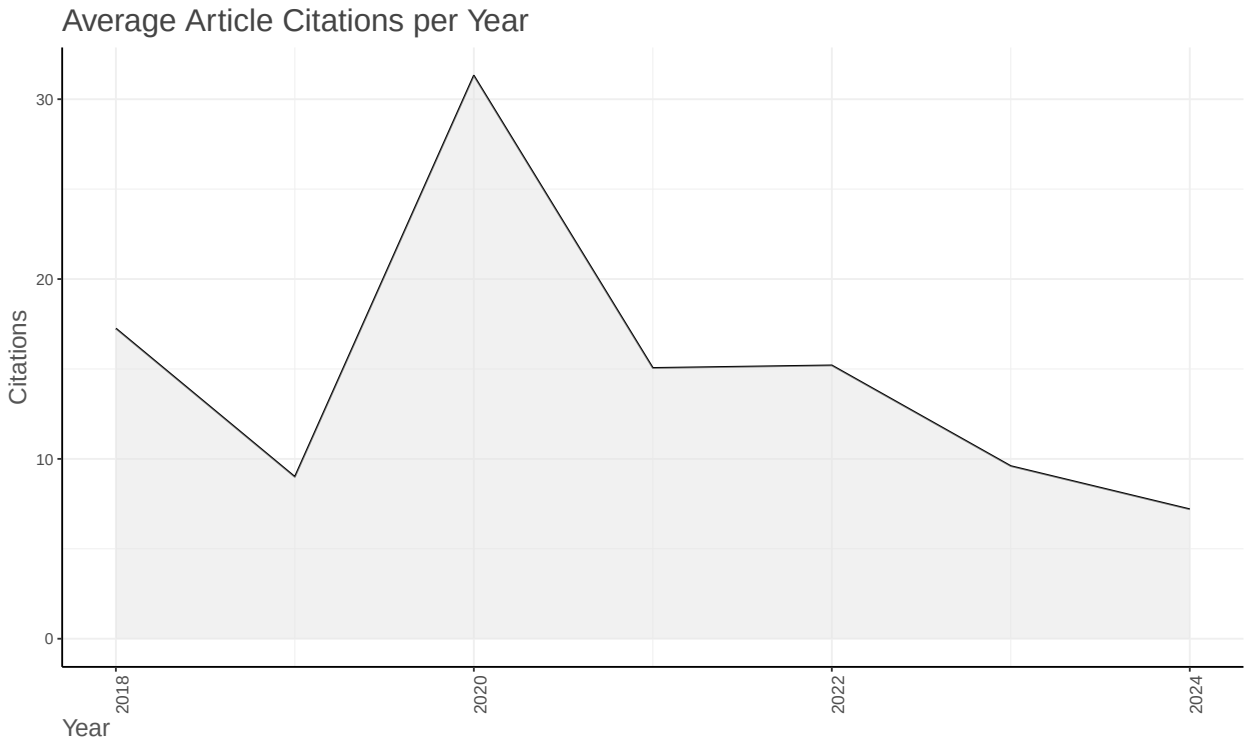

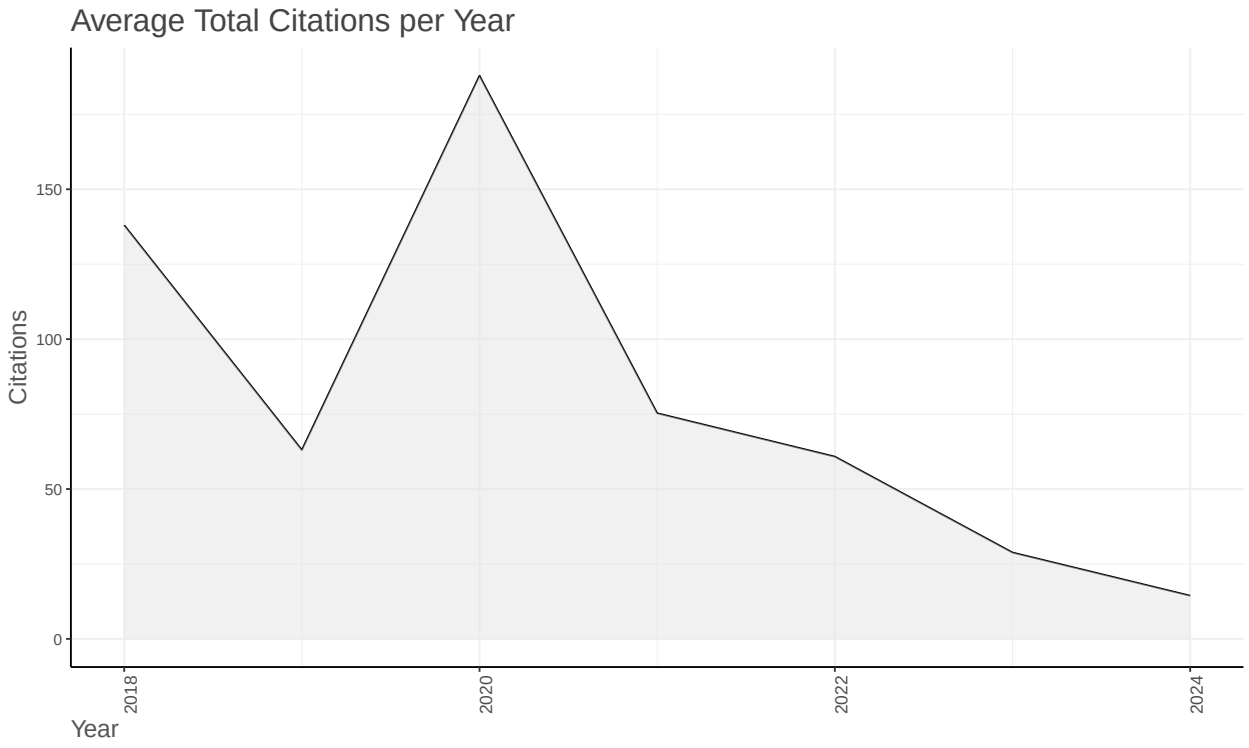

8 Exportar Dados Processados

Salvamos o dataframe limpo para uso nos notebooks seguintes.

```r
# Extrair metadados adicionais que não vêm prontos na importação
# AU_CO = país de cada autor (extraído do campo de afiliação C1)
# Necessário para análises de colaboração internacional no notebook 03
df <- metaTagExtraction(df, Field = "AU_CO", sep = ";")
cat("Campo AU_CO extraído:", sum(!is.na(df$AU_CO) & df$AU_CO != ""), "registros com país\n")
```

```
Campo AU_CO extraído: 653 registros com país
```

```r
# Salvar o dataframe processado em formato RDS (formato nativo do R, preserva tipos)
saveRDS(df, here("data", "processed", "df_bibliometria.rds"))

cat("Dados processados salvos em: data/processed/df_bibliometria.rds\n")
```

```
Dados processados salvos em: data/processed/df_bibliometria.rds
```

```r
cat("Total de artigos no dataset final:", nrow(df), "\n")
```

```
Total de artigos no dataset final: 671
```

9 Resumo

- **Artigos importados:** 671 (antes da limpeza)
- **Artigos no dataset final:** 671 (após remoção de duplicatas)
- **Período coberto:** 2018 a 2024
- **Dados salvos em:** `data/processed/df_bibliometria.rds`