01 — Importação e Limpeza dos Dados

Bibliometria de Gêmeos Digitais para Cidades Inteligentes

Leonardo Camilo

2026-03-20

Table of contents

1 Introdução **1**

2 Carregar Pacotes **1**

3 String de Busca **2**

4 Importar Dados **2**

5 Exploração Inicial **3**

6 Limpeza dos Dados **5**

6.1 Remover Duplicatas 5

6.2 Verificar Valores Ausentes 6

6.3 Verificar Período 7

7 Análise Bibliométrica Geral **7**

8 Exportar Dados Processados **13**

9 Resumo **14**

1 Introdução

Este notebook importa os dados bibliográficos exportados do Scopus e realiza a limpeza inicial do dataset. O resultado é um dataframe padronizado pronto para as análises bibliométricas dos notebooks seguintes.

2 Carregar Pacotes

```
library(bibliometrix)
library(tidyverse)
library(here)
```

3 String de Busca

A string de busca utilizada neste estudo:

`TITLE-ABS-KEY("digital twin*" AND ("smart cit*" OR "urban*"))`

Filtros aplicados:

- Período: 2015–2024
- Tipo de documento: Article
- Idioma: English

O operador `*` (truncamento) garante que variações como "digital twin" e "digital twins" sejam capturadas, assim como "smart city" e "smart cities", "urban" e "urbanization", etc.

4 Importar Dados

O `bibliometrix` possui a função `convert2df()` que converte arquivos bibliográficos de diversas fontes em um dataframe padronizado.

```r
# Caminhos para os arquivos exportados (Fase 3)
arquivo_scopus <- here("data", "raw", "scopus_2.bib")
arquivo_wos    <- here("data", "raw", "savedrecs.bib")

# Verificar se os arquivos existem
for (arq in c(arquivo_scopus, arquivo_wos)) {
  if (!file.exists(arq)) {
    stop("Arquivo não encontrado: ", arq)
  }
}

# Importar Scopus
df_scopus <- convert2df(file = arquivo_scopus, dbsource = "scopus", format = "bibtex")
```

```
Converting your scopus collection into a bibliographic dataframe


Warning:
In your file, some mandatory metadata are missing. Bibliometrix functions may not work properly

Please, take a look at the vignettes:
- 'Data Importing and Converting' (https://www.bibliometrix.org/vignettes/Data-Importing-and-Co
- 'A brief introduction to bibliometrix' (https://www.bibliometrix.org/vignettes/Introduction_t


Missing fields:  CR

Done!
```

```
Generating affiliation field tag AU_UN from C1:  Done!
```

```r
cat("Scopus - artigos importados:", nrow(df_scopus), "\n")
```

```
Scopus - artigos importados: 398
```

```r
# Importar Web of Science
df_wos <- convert2df(file = arquivo_wos, dbsource = "wos", format = "bibtex")
```

```
Converting your wos collection into a bibliographic dataframe

Done!


Generating affiliation field tag AU_UN from C1:  Done!
```

```r
cat("WoS - artigos importados:", nrow(df_wos), "\n")
```

```
WoS - artigos importados: 369
```

```r
# Combinar as duas bases
df <- mergeDbSources(df_scopus, df_wos, remove.duplicated = TRUE)
```

```
 316 duplicated documents have been removed
```

```r
cat("\nApós merge e remoção de duplicatas entre bases:", nrow(df), "\n")
```

```
Após merge e remoção de duplicatas entre bases: 451
```

```r
cat("Número de variáveis:", ncol(df), "\n")
```

```
Número de variáveis: 65
```

5 Exploração Inicial

Explorando a estrutura do dataset para entender os campos disponíveis.

```r
# Visualizar os primeiros registros
glimpse(df)
```

```
Rows: 451
Columns: 65
$ AU                        <chr> "CAO J;SPULBAR C;ETI S;HOROBET A;YUKSEL S;D~
$ KW_Merged                 <chr> "KNOWLEDGE-BASED SYSTEMS; SUSTAINABILITY; D~
$ DE                        <chr> "KNOWLEDGE-BASED SYSTEMS; SUSTAINABILITY; D~
$ ID                        <chr> NA, "INTERNET", "CHALLENGES", "PREDICTION; ~
$ C1                        <chr> "CAO, J (CORRESPONDING AUTHOR), LINYI UNIV,~
$ JI                        <chr> "J. INNOV. KNOWL.", "IEEE NETW.", "SUSTAINA~
$ AB                        <chr> "DIGITAL TWIN TECHNOLOGIES PLAY A VERY IMPO~
$ coden                     <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
```

```
$ RP                        <chr> "CAO, J (CORRESPONDING AUTHOR), LINYI UNIV,~
$ DI                        <chr> "10.1016/j.jik.2025.100651", "10.1109/MNET.~
$ SN                        <chr> "2530-7614", "0890-8044", NA, "2210-6707", ~
$ SO                        <chr> "JOURNAL OF INNOVATION \\& KNOWLEDGE", "IEE~
$ LA                        <chr> "ENGLISH", "ENGLISH", "ENGLISH", "ENGLISH",~
$ TC                        <dbl> 16, 12, 30, 21, 3, 0, 1, 0, 8, 170, 241, 13~
$ PN                        <chr> "1", "1", "18", NA, NA, "3", "9", "4", "48"~
$ PP                        <chr> NA, "238-246", NA, NA, NA, "257-290", NA, "~
$ pmid                      <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ publication_stage         <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ PU                        <chr> "ELSEVIER ESPANA", "IEEE-INST ELECTRICAL EL~
$ DB                        <chr> "ISI", "ISI", "ISI", "ISI", "ISI", "ISI", "~
$ TI                        <chr> "INNOVATIVE APPROACHES TO GREEN DIGITAL TWI~
$ DT                        <chr> "ARTICLE", "ARTICLE", "ARTICLE", "ARTICLE",~
$ url                       <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ VL                        <chr> "10", "38", "15", "126", NA, "26", "8", "17~
$ PY                        <dbl> 2025, 2024, 2023, 2025, 2025, 2025, 2023, 2~
$ AF                        <chr> "CAO JIFENG;SPULBAR CRISTI;ETI SERKAN;HOROB~
$ J9                        <chr> "J INNOV KNOWL", "IEEE NETW", "SUSTAINABILI~
$ AB_raw                    <chr> "Digital twin technologies play a very impo~
$ TI_raw                    <chr> "Innovative approaches to green digital twi~
$ DE_raw                    <chr> "Knowledge-based systems; Sustainability; D~
$ CR_raw                    <chr> "ABDULLA N, 2024, SUSTAIN ENERGY GRIDS, V38~
$ AU_UN                     <chr> "LINYI UNIV;LINYI UNIV;UNIV CRAIOVA;ISTANBU~
$ AU1_UN                    <chr> "LINYI UNIV", "XIDIAN UNIV", "NOTREPORTED;S~
$ AU_UN_NR                  <lgl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ SR_FULL                   <chr> "CAO J, 2025, J INNOV KNOWL", "LI G, 2024, ~
$ SR                        <chr> "CAO J, 2025, J INNOV KNOWL", "LI G, 2024, ~
$ PA                        <chr> "CALLE DE ZURBANO, 76-4TH FLR LEFT, MADRID,~
$ affiliations              <chr> "LINYI UNIVERSITY; UNIVERSITY OF CRAIOVA; I~
$ AR                        <chr> "100651", NA, "14002", "106356", NA, NA, "1~
$ EM                        <chr> "13305321132@163.COM", "TOM.LUAN@XIDIAN.EDU~
$ BO                        <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ da                        <chr> "2026-03-19", "2026-03-19", "2026-03-19", "~
$ GA                        <chr> "U1A6E", "OF3A7", "S6VX3", "1XR9K", "T5Y5U"~
$ eissn                     <chr> "2444-569X", "1558-156X", "2071-1050", "221~
$ earlyaccessdate           <chr> "JAN 2025", NA, NA, "APR 2025", "JAN 2025",~
$ BE                        <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ FU                        <chr> "NATIONAL SOCIAL SCIENCE FUND OF CHINA [24S~
$ FX                        <chr> "THIS RESEARCH WAS FUNDED BY THE NATIONAL S~
$ BN                        <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ month                     <chr> "JAN-MAR", "JAN", "SEP", "MAY 15", "2025 JA~
$ note                      <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ NR                        <chr> "36", "15", "35", "163", "71", "110", "69",~
$ oa                        <chr> "GREEN SUBMITTED, GOLD", NA, "GOLD", "GREEN~
$ orcid.numbers             <chr> "HOROBET, ALEXANA/0000-0001-5821-0244 ETI, ~
$ organization              <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ SC                        <chr> "BUSINESS \\& ECONOMICS", "COMPUTER SCIENCE~
```

```
$ researcherid.numbers       <chr> "HOROBET, ALEXANA/D-2301-2010 ETI, SERKAN/B~
$ SE                         <chr> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
$ UT                         <chr> "WOS001409208300001", "WOS001205799800034",~
$ usage.count.last.180.days  <chr> "18", "13", "15", "42", "17", "4", "2", "0"~
$ U2                         <chr> "38", "44", "129", "60", "32", "4", "28", "~
$ web.of.science.categories. <chr> "BUSINESS; MANAGEMENT", "COMPUTER SCIENCE, ~
$ web.of.science.index       <chr> "SOCIAL SCIENCE CITATION INDEX (SSCI)", "SC~
$ CR                         <chr> "NA", "NA", "NA", "NA", "NA", "NA", "NA", "~
$ DB_Original                <chr> "ISI", "ISI", "ISI", "ISI", "ISI", "ISI", "~
```

```r
# Campos mais relevantes para a análise bibliométrica:
# AU = Autores
# TI = Título
# SO = Periódico (Source)
# DT = Tipo de documento
# DE = Keywords do autor
# ID = Keywords Plus (indexadas)
# AB = Abstract
# TC = Total de citações
# PY = Ano de publicação
# AU_CO = País do primeiro autor

# Verificar campos disponíveis
cat("Campos disponíveis no dataset:\n")
```

```
Campos disponíveis no dataset:
```

```r
cat(paste(names(df), collapse = ", "), "\n")
```

```
AU, KW_Merged, DE, ID, C1, JI, AB, coden, RP, DI, SN, SO, LA, TC, PN, PP, pmid, publication_sta
```

6 Limpeza dos Dados

6.1 Remover Duplicatas

```r
# mergeDbSources já removeu duplicatas entre bases pelo DOI
# Aqui removemos duplicatas residuais pelo título (mais robusto, pois DOI pode faltar)
n_antes <- nrow(df)

df <- df %>%
  distinct(TI, .keep_all = TRUE)

n_depois <- nrow(df)
n_removidos <- n_antes - n_depois

cat("Artigos antes da remoção residual por título:", n_antes, "\n")
```

```
Artigos antes da remoção residual por título: 451
```

```r
cat("Artigos após remoção:", n_depois, "\n")
```

```
Artigos após remoção: 451
```

```r
cat("Duplicatas residuais removidas:", n_removidos, "\n")
```

```
Duplicatas residuais removidas: 0
```

6.2 Verificar Valores Ausentes

```r
# Verificar proporção de NAs nos campos mais importantes
campos_chave <- c("AU", "TI", "SO", "PY", "TC", "DE", "ID", "AB")

# Calcular NAs para cada campo
na_info <- sapply(campos_chave, function(campo) {
  if (campo %in% names(df)) {
    sum(is.na(df[[campo]]) | df[[campo]] == "")
  } else {
    NA
  }
})

# Exibir resultado
na_tabela <- data.frame(
  Campo = campos_chave,
  Descricao = c("Autores", "Título", "Periódico", "Ano",
                "Citações", "Keywords Autor", "Keywords Plus", "Abstract"),
  NAs = na_info,
  Percentual = round(na_info / nrow(df) * 100, 1)
)

knitr::kable(na_tabela, caption = "Valores ausentes nos campos principais")
```

Table 1: Valores ausentes nos campos principais

	Campo	Descricao	NAs	Percentual
AU	AU	Autores	0	0.0
TI	TI	Título	0	0.0
SO	SO	Periódico	0	0.0
PY	PY	Ano	0	0.0
TC	TC	Citações	0	0.0
DE	DE	Keywords Autor	7	1.6
ID	ID	Keywords Plus	157	34.8
AB	AB	Abstract	0	0.0

6.3 Verificar Período

```r
# Confirmar que todos os artigos estão no período desejado (2015-2024)
cat("Período dos dados:\n")
```

```
Período dos dados:
```

```r
cat("  Ano mínimo:", min(df$PY, na.rm = TRUE), "\n")
```

```
  Ano mínimo: 2020
```

```r
cat("  Ano máximo:", max(df$PY, na.rm = TRUE), "\n")
```

```
  Ano máximo: 2026
```

```r
# Tabela de frequência por ano
table(df$PY) %>%
  as.data.frame() %>%
  setNames(c("Ano", "Artigos")) %>%
  knitr::kable(caption = "Distribuição de artigos por ano")
```

Table 2: Distribuição de artigos por ano

Ano	Artigos
2020	10
2021	16
2022	36
2023	47
2024	99
2025	181
2026	62

7 Análise Bibliométrica Geral

O `bibliometrix` oferece a função `biblioAnalysis()` que gera um resumo completo das principais estatísticas do corpus.

Glossário das métricas do `summary(biblioAnalysis())`:

- **TC** — *Total Citations*: número total de citações recebidas pelo artigo
- **NTC** — *Normalized Total Citations*: citações normalizadas pelo ano de publicação (permite comparar artigos de anos diferentes)
- **TCperYear** — *Total Citations per Year*: média de citações por ano desde a publicação
- **SCP** — *Single Country Publications*: artigos em que todos os autores são do mesmo país (sem colaboração internacional)
- **MCP** — *Multiple Country Publications*: artigos com autores de dois ou mais países (colaboração internacional)
- **MCP_Ratio** — Proporção de MCP sobre o total de publicações do país. Valores próximos de 1 indicam que quase toda a produção do país é feita em colaboração internacional; valores próximos de 0 indicam produção predominantemente doméstica

```r
# Gerar análise bibliométrica geral
resultados <- biblioAnalysis(df)

# Exibir resumo das principais métricas
summary(resultados, k = 10)
```

```
MAIN INFORMATION ABOUT DATA

 Timespan                              2020 : 2026
 Sources (Journals, Books, etc)        249
 Documents                             451
 Annual Growth Rate %                  35.54
 Document Average Age                  1.78
 Average citations per doc             19.34
 Average citations per year per doc    4.396
 References                            1

DOCUMENT TYPES
 article                            430
 article; early access              19
 article; proceedings paper         1
 article; retracted publication     1

DOCUMENT CONTENTS
 Keywords Plus (ID)                    1028
 Author's Keywords (DE)                1818

AUTHORS
 Authors                               1790
 Author Appearances                    2092
 Authors of single-authored docs       36

AUTHORS COLLABORATION
 Single-authored docs                  36
 Documents per Author                  0.252
 Co-Authors per Doc                    4.64
 International co-authorships %        28.82


Annual Scientific Production

 Year    Articles
    2020       10
    2021       16
    2022       36
```

2023	47
2024	99
2025	181
2026	62

Annual Percentage Growth Rate 35.54

Most Productive Authors

	Authors	Articles	Authors	Articles Fractionalized
1	WANG Y	11	WANG Y	2.65
2	LI Y	8	LIU Y	2.02
3	LIU Y	8	ZHANG H	1.51
4	LI X	7	CHEN Y	1.48
5	CHEN Y	6	ZHU M	1.37
6	BIBRI S	5	BIBRI S	1.37
7	HUANG J	5	GIL J	1.33
8	JIANG Y	5	HUANG J	1.26
9	LI Z	5	KANG J	1.25
10	ZHANG H	5	KIM J	1.25

Top manuscripts per citations

	Paper	DOI	TC
1	DENG T, 2021, J MANAG SCI ENG	10.1016/j.jmse.2021.03.003	517
2	BOTIN-SANABRIA D, 2022, REMOTE SENS	10.3390/rs14061335	472
3	DENG M, 2021, J INF TECHNOL CONSTR	10.36680/J.ITCON.2021.005	378
4	DEMBSKI F, 2020, SUSTAINABILITY	10.3390/su12062307	358
5	SCHROTTER G, 2020, PFG-J PHOTOGRAMM REMOTE SENS GEOINF SCI	10.1007/s41064-020-00092-2	340
6	ALLAM Z, 2022, SMART CITIES	10.3390/smartcities5030040	312
7	LI X, 2022, FUTUR GENER COMP SYST	10.1016/j.future.2021.10.006	241
8	WEIL C, 2023, SUSTAINABLE CITIES SOC	10.1016/j.scs.2023.104862	217
9	SHAHZAD M, 2022, BUILDINGS-BASEL	10.3390/buildings12020120	209
10	KETZLER B, 2020, BUILT ENVIRON	10.2148/BENV.46.4.547	209

Corresponding Author's Countries

	Country	Articles	Freq	SCP	MCP	MCP_Ratio
1	CHINA	107	0.2518	78	29	0.271
2	USA	41	0.0965	29	12	0.293
3	ITALY	33	0.0776	29	4	0.121
4	UNITED KINGDOM	26	0.0612	19	7	0.269
5	SPAIN	16	0.0376	13	3	0.188
6	INDIA	14	0.0329	9	5	0.357
7	AUSTRALIA	12	0.0282	10	2	0.167

8	IRAN	10	0.0235	5	5	0.500
9	KOREA	10	0.0235	7	3	0.300
10	NETHERLANDS	10	0.0235	5	5	0.500

SCP: Single Country Publications

MCP: Multiple Country Publications

Total Citations per Country

	Country	Total Citations	Average Article Citations
1	CHINA	1811	16.925
2	USA	734	17.902
3	UNITED KINGDOM	503	19.346
4	MEXICO	492	164.000
5	FRANCE	457	57.125
6	NETHERLANDS	448	44.800
7	SWITZERLAND	387	48.375
8	SPAIN	369	23.062
9	ITALY	307	9.303
10	INDIA	230	16.429

Most Relevant Sources

	Sources	Articles
1	SUSTAINABILITY	20
2	SUSTAINABLE CITIES AND SOCIETY	16
3	SMART CITIES	13
4	IEEE ACCESS	12
5	BUILDINGS	8
6	CITIES	8
7	URBAN SCIENCE	8
8	ADVANCED ENGINEERING INFORMATICS	7
9	APPLIED SCIENCES-BASEL	7
10	AUTOMATION IN CONSTRUCTION	7

Most Relevant Keywords

	Author Keywords (DE)	Articles	Keywords-Plus (ID)	Articles
1	DIGITAL TWIN	191	DECISION MAKING	29
2	DIGITAL TWINS	77	SMART CITY	29
3	SMART CITY	59	MANAGEMENT	26
4	SMART CITIES	53	CHALLENGES	25
5	ARTIFICIAL INTELLIGENCE	31	MODEL	24

```
6    SUSTAINABILITY              30        FRAMEWORK            22
7    INTERNET OF THINGS          22        BIG DATA             21
8    URBAN PLANNING              22        CITY                 21
9    URBAN                       20        SYSTEM               21
10   URBAN DIGITAL TWIN          19        DESIGN               20
```

```r
# Gráficos automáticos do bibliometrix
# Estes gráficos dão uma visão geral rápida do corpus
plot(resultados, k = 10)
```

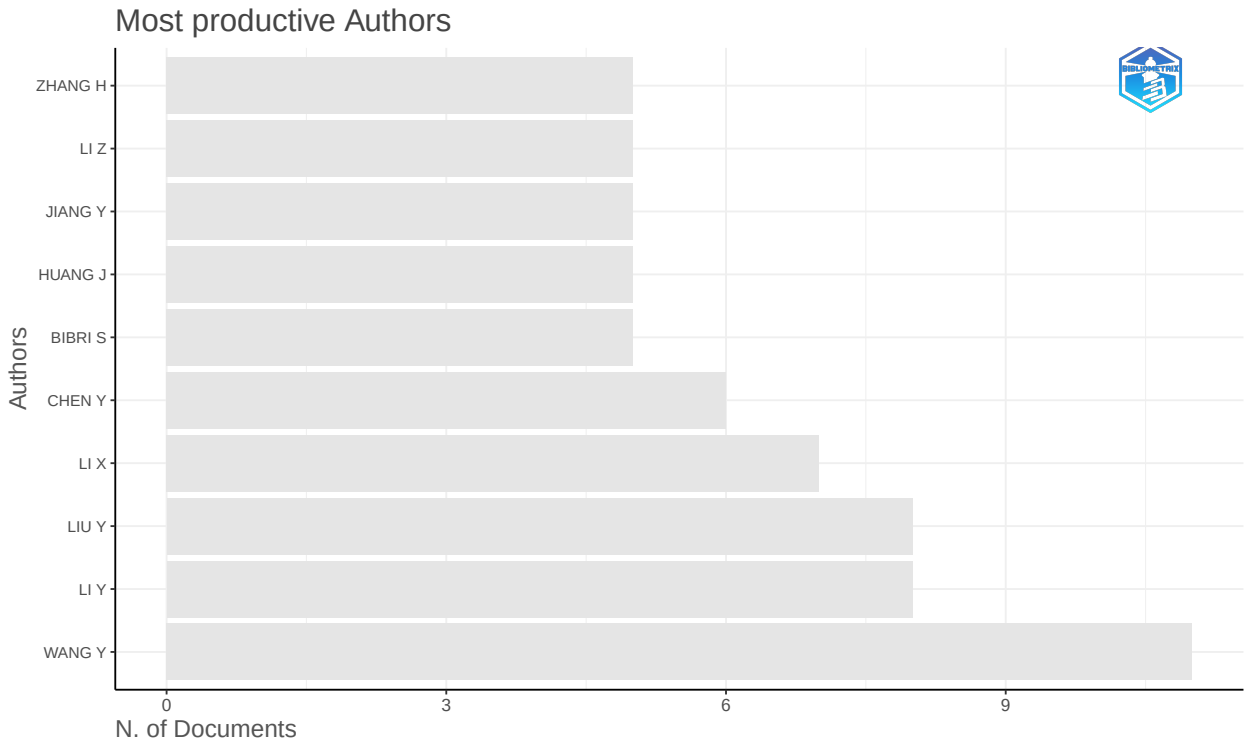

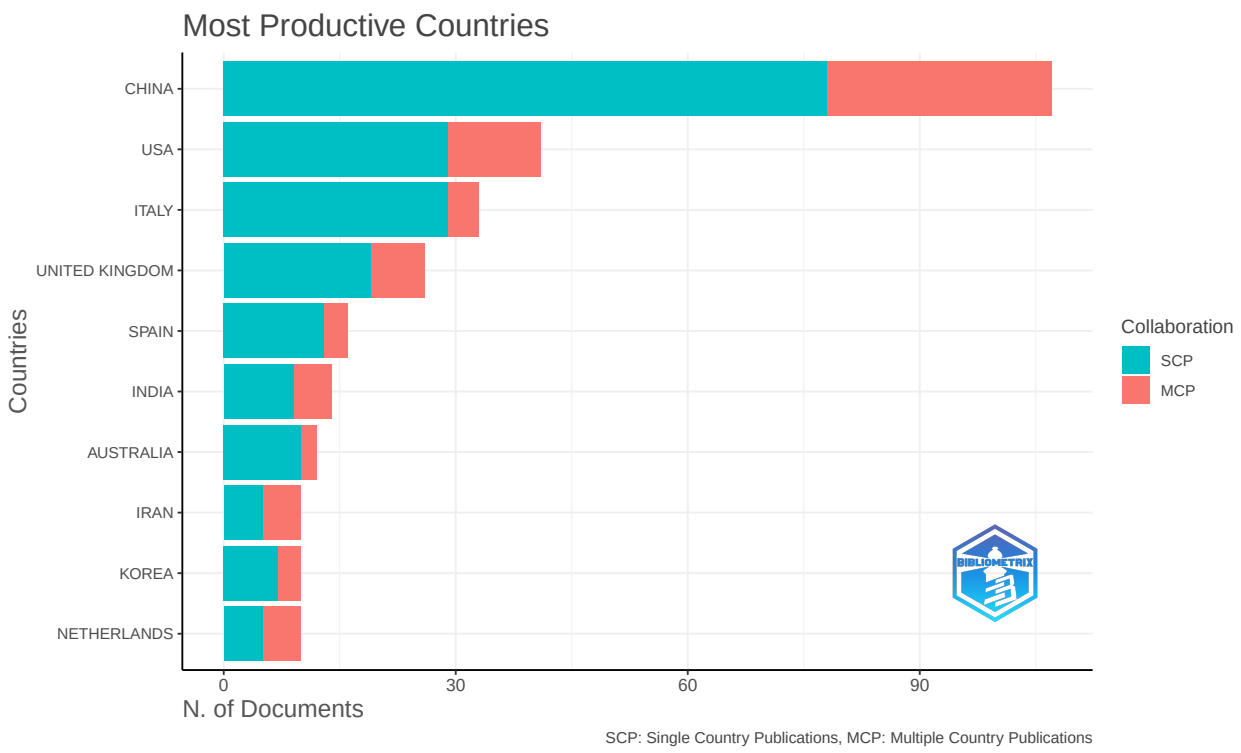
Most Productive Countries
CHINA
USA
ITALY
UNITED KINGDOM
SPAIN
INDIA
AUSTRALIA
IRAN
KOREA
NETHERLANDS
Countries
0
30
60
90
N. of Documents
Collaboration
SCP
MCP
SCP: Single Country Publications, MCP: Multiple Country Publications

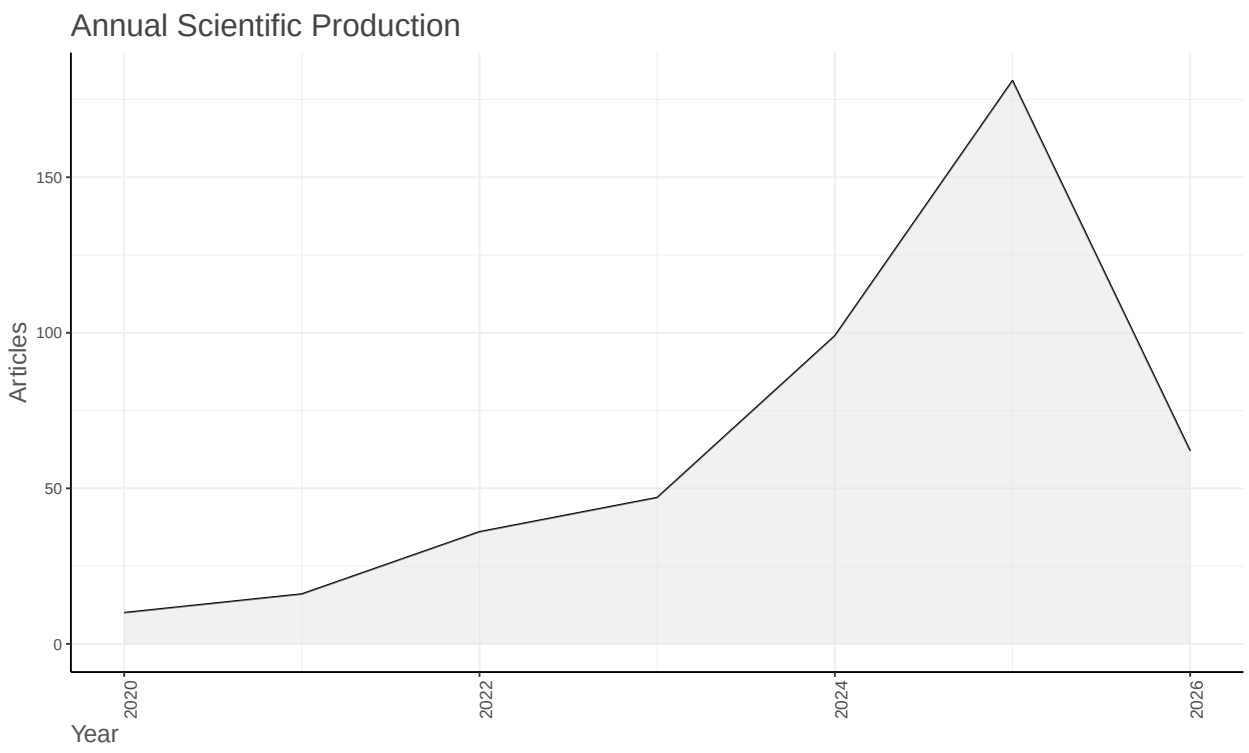
Annual Scientific Production
150
100
50
0
Articles
2020
2022
2024
2026
Year

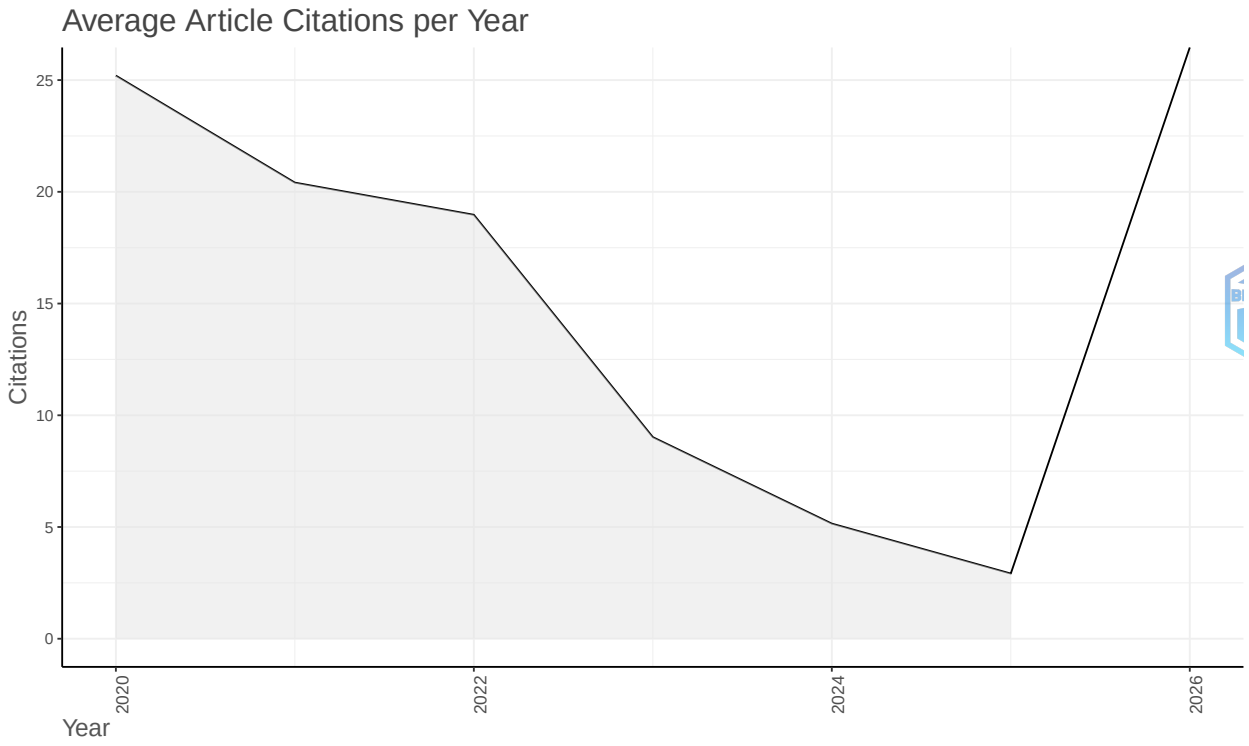

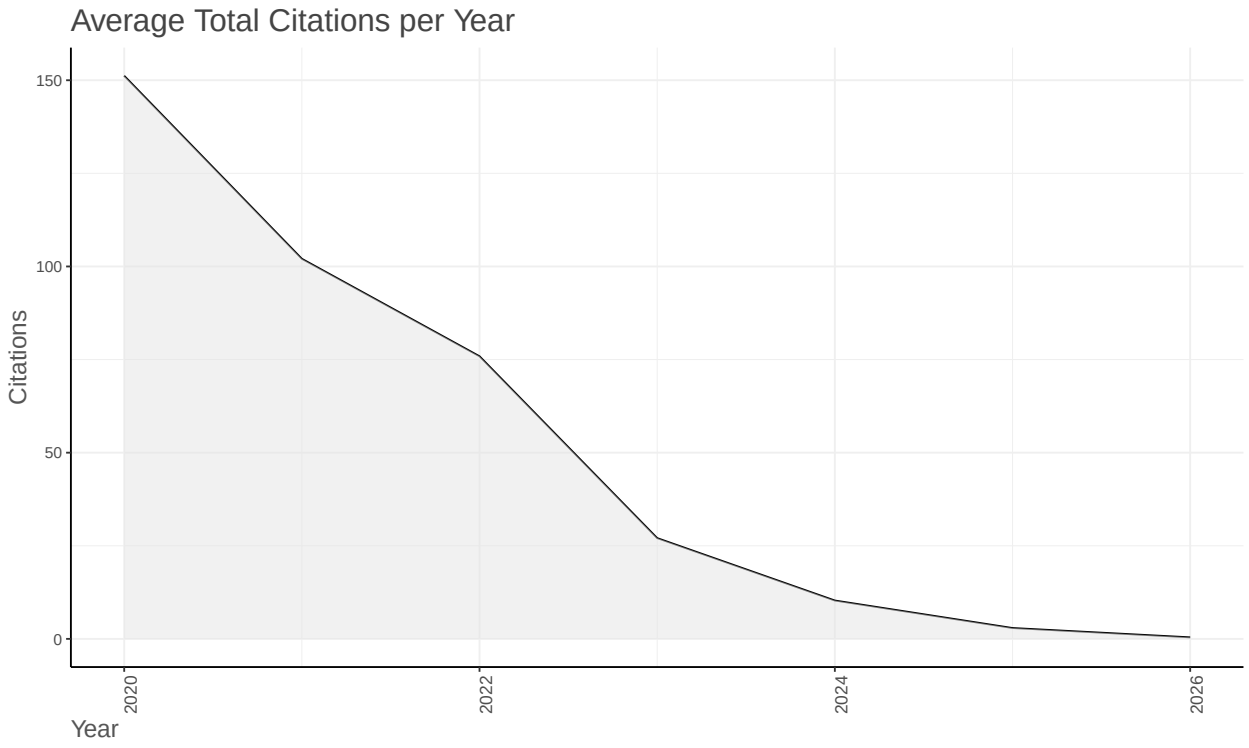

8 Exportar Dados Processados

Salvamos o dataframe limpo para uso nos notebooks seguintes.

```r
# Extrair metadados adicionais que não vêm prontos na importação
# AU_CO = país de cada autor (extraído do campo de afiliação C1)
# Necessário para análises de colaboração internacional no notebook 03
df <- metaTagExtraction(df, Field = "AU_CO", sep = ";")
cat("Campo AU_CO extraído:", sum(!is.na(df$AU_CO) & df$AU_CO != ""), "registros com país\n")
```

```
Campo AU_CO extraído: 444 registros com país
```

```r
# Salvar o dataframe processado em formato RDS (formato nativo do R, preserva tipos)
saveRDS(df, here("data", "processed", "df_bibliometria.rds"))

cat("Dados processados salvos em: data/processed/df_bibliometria.rds\n")
```

```
Dados processados salvos em: data/processed/df_bibliometria.rds
```

```r
cat("Total de artigos no dataset final:", nrow(df), "\n")
```

```
Total de artigos no dataset final: 451
```

9 Resumo

- **Scopus:** 398 artigos | **WoS:** 369 artigos
- **Artigos no dataset final:** 451 (após merge e remoção de duplicatas)
- **Período coberto:** 2020 a 2026
- **Dados salvos em:** `data/processed/df_bibliometria.rds`